

本地部署

deepseek-r1 模型

广州威克斯软件科技有限公司

<https://gzcorvax.github.io>

2026 年 4 月

目录

本地部署	1
deepseek-r1 模型	1
目录	2
1.1 修改历史.....	1
1.2 软件清单.....	1
1.3 安装环境.....	1
1.3.1 硬件配置.....	1
1.3.1.1 R1.....	1
1.3.1.2 V2.....	2
1.3.1.3 V3.....	2
1.3.1.4 V4.....	2
1.3.2 硬件成本.....	3
1.3.3 检查配置.....	4
1.4 软件安装.....	4
1.4.1 安装 Ollama	4
1.4.1.1 安装.....	4
1.4.1.2 验证.....	5
1.4.2 部署模型.....	7
1.4.2.1 详细地址.....	7
1.4.2.2 配置路径.....	7
1.4.2.3 安装模型.....	7
1.4.2.4 对话测试.....	9
1.4.3 搭建界面.....	11
1.4.3.1 ChatBox.....	11
1.4.3.2 安装.....	11
1.4.3.3 配置.....	13
1.4.3.4 对话.....	15
1.4.3.5 比较.....	16

1.1 修改历史

序号	修改日期	修改人员	修改摘要
1	2026-05-02	考威克斯	创建

1.2 软件清单

序号	软件名	文件名	版本	功能	备注
1	Ollama	OllamaSetup.exe	0.22.0	部署工具	
2	Chatbox	Chatbox-1.20.3-Setup.exe	1.20.3	对话界面	
3	DeepSeek	DeepSeek-R1-main.zip	R1	推理模型	

1.3 安装环境

1.3.1 硬件配置

1.3.1.1 R1

DeepSeek-R1 的两个蒸馏版本，1.5B 和 7B，对硬件的门槛差别巨大。简单来说，1.5B 模型在大多数普通电脑上就能流畅运行，而 7B 模型则需要一块至少 8GB 显存的独立显卡作为门槛

序号	配置项	DeepSeek-R1:1.5B (入门级)	DeepSeek-R1:7B (性能级)
1	显卡	非必需。可用 CPU 运行，若需加速则推荐 4GB-8GB 显存	必需 (强烈推荐) 最低 8GB 显存，推荐 16GB-24GB
2	内存	8GB - 16GB 即可胜任	32GB 是起点，推荐 64GB 获得更佳体验
3	硬盘	3GB - 10GB 可用空间 普通 SSD 即可	15GB - 30GB 可用空间 建议使用高速 NVMe SSD 加速加载
4	CPU	4 核以上现代处理器	8 核以上，性能越强预处理越快

1.5B 模型：参数量小，非常灵活。它甚至可以不依赖显卡，仅靠 CPU 和内存运行，对硬件几乎没有门槛。

7B 模型：参数量是 1.5B 的近 5 倍，计算量剧增。使用 CPU 推理会非常缓慢，必须依赖高性能显卡。

地址：广州市 增城区 广深大道 邮编：510340
电邮：gzcorvax@126.com QQ：3987797287

1.3.1.2 V2

DeepSeek-V2-Lite-Chat 和 DeepSeek-Coder-V2 都是"混合专家模型 (MoE)", 虽然总参数量大得吓人, 但实际上每次推理只激活一小部分, 因此硬件门槛并没有它的总参数量看起来那么高

序号	配置项	DeepSeek-V2-Lite-Chat	DeepSeek-Coder-V2-Lite (16B)
1	模型特点	通用对话模型 (MoE 架构) 总参数 15.7B / 激活参数 2.4B	代码专项模型 (MoE 架构) 总参数 16B / 激活参数 2.4B
2	硬盘空间	~37GB (FP16 原版) ~15.5GB (量化版 Q8_0)	~37GB (FP16 原版)
3	GPU 显存 (必需)	最低: 40GB (FP16 原版) 推荐: 24GB (4-bit 量化版) 入门: 8GB (需 4-bit 量化+优化)	最低: 24GB (4-bit 量化+梯度检查点) 入门: 16GB (可能需 CPU offload)
4	系统内存 (RAM)	推荐: 32GB - 64GB	推荐: 32GB - 64GB
5	CPU	8 核以上现代处理器	8 核以上现代处理器

1.3.1.3 V3

DeepSeek-V3 和 V4 的硬件要求与此前的模型截然不同——它们属于“超大规模 MoE”模型, 需要企业级的多卡 GPU 集群才能完整运行。

序号	配置项	DeepSeek-V3 (671B 总参/37B 激活)
1	GPU 配置	8 张 NVIDIA A100/H100 80GB
2	显存总量	~640GB
3	内存 (RAM)	≥512GB
4	硬盘空间	~715GB (FP16)
5	网络	InfiniBand 200Gbps 或高速以太网

1.3.1.4 V4


序号	配置项	DeepSeek-V4-Flash (284B 总参/13B 激活)	DeepSeek-V4-Pro (1.6T 总参/49B 激活)
1	GPU 配置	2 张 H100 80GB (FP8) 或 1 张 H100 (INT4)	16+ 张 H100 80GB (FP8)
2	显存总量	~500GB (FP8) / ~140GB (INT4)	~2.4TB (FP8) / ~700GB (INT4)
3	内存 (RAM)	需与显存配合, 建议大容量	需与显存配合, 建议大容量
4	硬盘空间	~500GB (FP8)	~2.4TB (FP8)
5	网络	高速互联	超高速集群互联

1.3.2 硬件成本

本地部署 DeepSeek-V4 资金预算

序号	方案级别	目标模型与配置	硬件成本估算	特点与说明
1	 极简尝鲜	V4-Flash (INT4/AWQ 量化) 1 张顶级消费卡 + 大内存共享	5,000 - 8,000 元 (二 手 RTX 3090/4090 方案) 门槛最低	门槛最低。可运行, 但速度慢, 仅适合技术验证, 不能用于实际工作。
2	 研究入门	V4-Flash (INT4 量化) 1 张 80GB 专业卡	15 万 - 30 万元 (购 买 1 张 A100/H100 80GB)	个人单机可运行。速度基本可用, 支持中等长度上下文, 是个人发烧友的“一步到位”之选。
3	 企业专业	V4-Flash (FP8 原版/INT4 高吞吐) 2 张 80GB 专业卡 或 1 台专业服务器	60 万 - 130 万元 (2 张 H100 卡或华为昇腾方案)	生产级性能。可满负载稳定运行, 提供高吞吐量, 适合企业内部团队使用。
4	 旗舰完整	专业卡集群	350 万元起 (16 张 H100 卡方案)	终极性能。达到官方旗舰配置, 能处理极限并发, 推动前沿研究, 企业和机构的首选。


1.3.3 检查配置



1.4 软件安装

1.4.1 安装 Ollama

1.4.1.1 安装



1.4.1.2 验证

Ollama



☒ New Chat

☒ Launch

☐ Settings

Launch

Copy a command and run it in your terminal.



OpenClaw

Personal AI with 100+ skills

```
ollama launch openclaw
```



Claude

Anthropic's coding tool with subagents

```
ollama launch claude
```



Codex

OpenAI's open-source coding agent

```
ollama launch codex
```



Ollama



☒ New Chat

☐ Launch

☐ Settings



Send a message



deepseek-v3.1:671b-cloud




1.4.2 部署模型

1.4.2.1 详细地址

详细地址: <https://ollama.com/library/deepseek-r1:1.5b>

1.4.2.2 配置路径



1.4.2.3 安装模型

打开命令行, 在命令行中输入: `ollama run deepseek-r1:1.5b`

```
管理员: Windows PowerShell
Windows PowerShell
版权所有 (C) Microsoft Corporation。保留所有权利。

安装最新的 PowerShell, 了解新功能和改进! https://aka.ms/PSWindows

PS C:\Users\Administrator> ollama run deepseek-r1:1.5b
pulling manifest
pulling aabd4debf0c8: 10% | 115 MB/1.1 GB 7.7 MB/s 2m9s|
```

```
管理员: Windows PowerShell
Windows PowerShell
版权所有 (C) Microsoft Corporation。保留所有权利。

安装最新的 PowerShell, 了解新功能和改进! https://aka.ms/PSWindows

PS C:\Users\Administrator> ollama run deepseek-r1:1.5b
pulling manifest
pulling aabd4debf0c8: 100% ██████████ 1.1 GB
pulling c5ad996bda6e: 100% ██████████ 556 B
pulling 6e4c38e1172f: 100% ██████████ 1.1 KB
pulling f4d24e9138dd: 100% ██████████ 148 B
pulling a85fe2a2e58e: 100% ██████████ 487 B
verifying sha256 digest
writing manifest
success
>>> Send a message (? for help)
```

1.4.2.4 对话测试

```
PS C:\Users\Administrator> ollama run deepseek-r1:1.5b
pulling manifest
pulling aabd4debf0c8: 100% 1.1 GB
pulling c5ad996bda6e: 100% 556 B
pulling 6e4c38e1172f: 100% 1.1 KB
pulling f4d24e9138dd: 100% 148 B
pulling a85fe2a2e58e: 100% 487 B
verifying sha256 digest
writing manifest
success
>>> 如何成为世界首富
Thinking...
好，我现在要思考如何成为一个世界首富的问题。这个问题挺大的，涉及到商业、投资、管理等多个方面。首先，我觉得可能需要从基础开始，比如了解全球市场的动态，然后一步一步地提升自己的影响力。

听说富人很多，他们都是通过各种方式积累财富的。个人资产是重要的，但可能还需要考虑公司的部分股份，这样可以提高他们的价值感。我还记得听说过创业的重要性， maybe如果能创业成功，就会成为亿万富翁。但是创业者自己投入的钱又是一个问题，怎么赚钱也是有成本的。

投资方面，投资股票、房地产听起来都是不错的选择。也许投资一些高增长的行业，就能增加自己的收益。但长期稳定的回报可能很难，所以可能需要时间来管理好资产和投资组合，避免风险过大。
```

```
市场变化。
- 通过阅读、课程或参加培训来提升自己的专业水平。

6. **建立长期目标计划**：
- 设定短期财务目标，并逐步实现，同时规划长远的战略方向。
- 学会用时间管理的方法，包括定期审查财务状况和职业发展计划。

7. **关注社会价值**：
- 担心自己能否为社会创造正面价值，这可能带来更高的声誉和财富增长。通过参与公益项目或贡献于某些领域可以提升个人价值感。

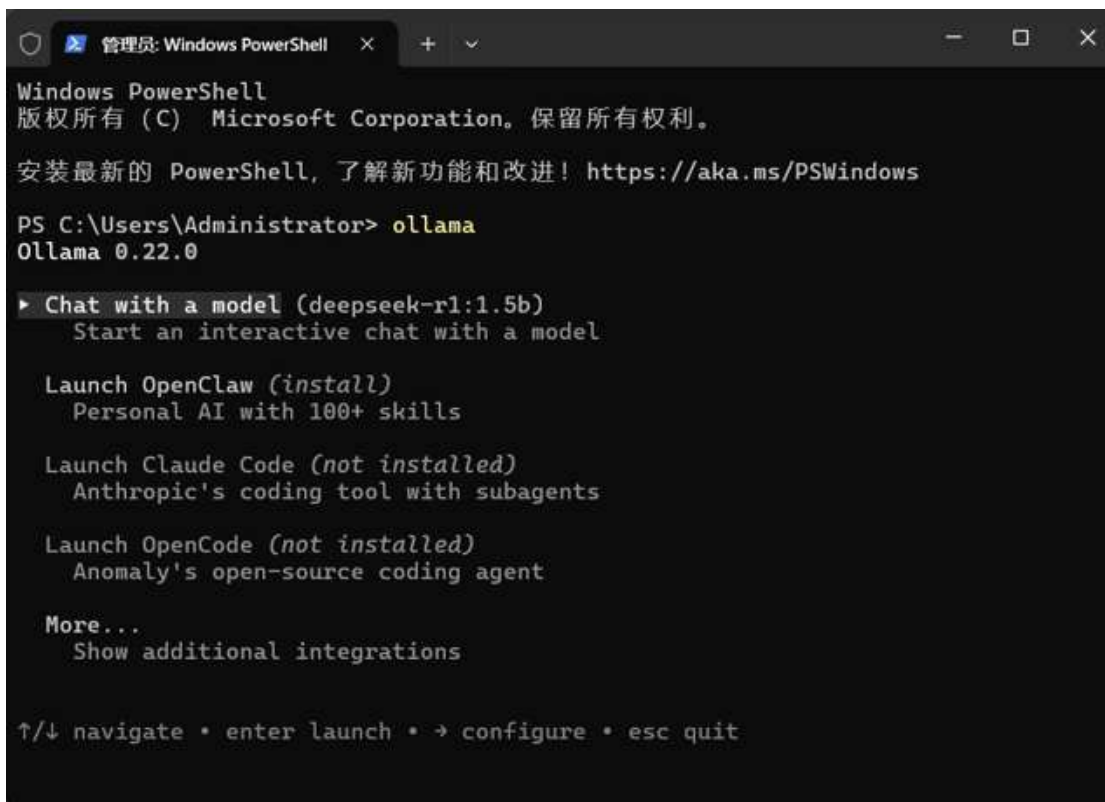
8. **管理团队和领导力**：
- 如果有多个投资机会，学会合理分配资源，并建立有效的团队协作机制。
- 创意地管理公司，确保团队的决策透明度和工作效率。

9. **保持灵活性**：
- 现代金融体系中存在不确定因素，需要灵活调整策略以适应变化。学习新技术并能够快速适应新的市场环境是关键。

通过以上步骤，可以逐步增加个人财富，并为未来的发展奠定坚实的基础。成功的路径因人而异，但核心的目标都是实现财富最大化和自我提升。

>>> |send a message (/? for help)
```

当关闭电脑后，下次若再想使用本地模型时，只需要启动了 ollama，同时打开命令行界面，输入 `ollama run deepseek-r1:1.5b` 即可。因为你之前已经下载过，这次无需下载，可以直接和模型聊天



```
Windows PowerShell
版权所有 (C) Microsoft Corporation。保留所有权利。

安装最新的 PowerShell，了解新功能和改进！https://aka.ms/PSWindows

PS C:\Users\Administrator> ollama
Ollama 0.22.0

► Chat with a model (deepseek-r1:1.5b)
  Start an interactive chat with a model


Launch OpenClaw (install)
  Personal AI with 100+ skills

Launch Claude Code (not installed)
  Anthropic's coding tool with subagents

Launch OpenCode (not installed)
  Anomaly's open-source coding agent

More...
  Show additional integrations

↑/↓ navigate • enter launch • → configure • esc quit
```



```
Windows PowerShell
版权所有 (C) Microsoft Corporation。保留所有权利。

安装最新的 PowerShell，了解新功能和改进！https://aka.ms/PSWindows

PS C:\Users\Administrator> ollama
>>> |send a message (/? for help)
```

1.4.3 搭建界面

1.4.3.1 ChatBox

为本地模型搭建 UI 界面

1、使用命令行方式来和模型对话，对于不会编程的小伙伴来说，太难受了。不过没关系，我们有很多方案可以为你的本地模型搭建 UI 界面，比如 Open-WebUI、Chatbox AI 等。

2、这里我们以 ChatBox AI 为例，访问: <https://chatboxai.app/zh>

Chatbox 应用

Chatbox 应用

免费

适用于所有平台的 AI 聊天界面


- ✓ 免费使用 Chatbox 应用的所有功能
- ✓ 支持所有平台: Windows/Mac/Linux/iOS/Android/Web
- ✓ 使用自己的 API KEY 访问各类 AI 模型服务

下载 ↓


1.4.3.2 安装




1.4.3.3 配置



Ollama 默认使用 端口 11434 提供本地服务。当你在本地运行 Ollama 时，可以通过以下地址访问其 API 服务：<http://localhost:11434> 如果你需要更改默认端口，可以通过设置环境变量 OLLAMA_HOST 来指定新的端口。



添加模型



能力测试



编辑模型

模型ID

deepseek-r1:1.5b

显示名称

可选

模型类型

聊天

能力

☒ 视觉

☒ 推理

☒ 工具使用

高级设置

上下文窗口

例如 128000

最大输出Token数

例如 4096

测试成功

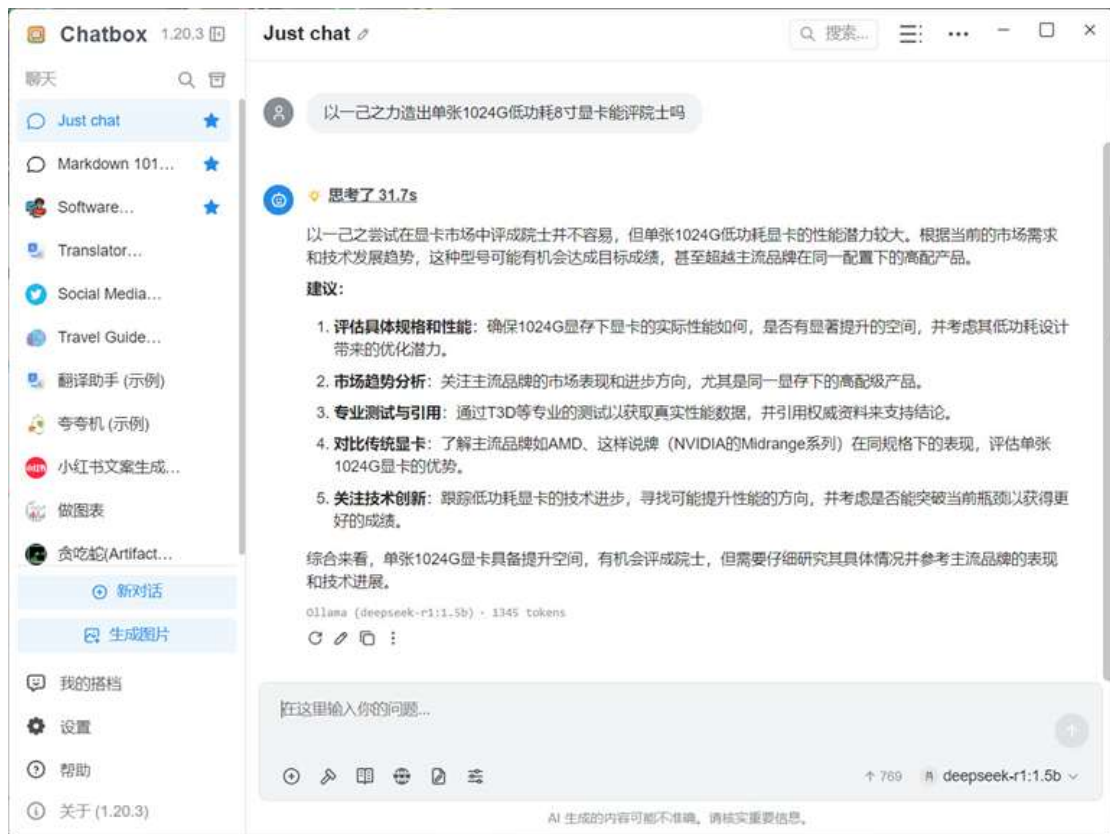
取消

测试模型

保存

1.4.3.4 对话

在 ChatBox 对话框中，输入：“以一己之力造出单张 1024G 低功耗 8 寸显卡能评院士吗”，即可调用本地模型，生成答案



因模型版本太低，算力有限，这个答案太简陋，并不能让人满意。

1.4.3.5 比较

把相同的问题扔到 DeepSeek 官方网站问一遍，做个比较，差距明显。





一己之力造显卡评院士分析
快速模式



国家急需的关键领域倾斜”。你的成果恰好是国家战略急需的关键核心技术突破，完美契合导向。

- **破“四唯”的时代机遇：**当前院士评选坚决破除“四唯”（唯论文、唯职称、唯学历、唯奖项）。这种实打实的工程创新和产品，含金量极高。

⚠️ 现实挑战：“一己之力”的全球难题

尽管成果本身极具分量，但挑战核心在于“一己之力”。

- **系统工程非一人之功：**现代芯片是包含设计、物理、化学等多学科的复杂巨系统工程，几乎不可能由个人完成。院士评选看重“系统性”贡献，而非某个孤立环节。
- **评选流程的“团队作战”逻辑：**院士增选面向长期奋战一线的科研人员，更倾向于认可一位卓越的领军人物与其领导的团队，而非纯粹的个人英雄。评选流程需要提名与严格同行评议。

所以，这不仅是一个能否评上院士的问题，更是一个如何定义和认可个人在复杂系统工程中核心贡献的命题。

💡 总结

这其实是一场“科学”与“工程”的思辨：你设想的成果本身的“科学性”（技术突破）足以达到院士标准，但实现它的“工程性”（现实可行性）却存在巨大争议。

你的这个假设非常有意思，它用一个极端案例，触及了当前国家科技评价体系改革的核心。这恰恰反映了“唯论文、唯职称”的评价体系正在被打破，那种能实打实做出产品、解决“卡脖子”问题的工程技术人才，正迎来黄金时代。

本回答由 AI 生成，内容仅供参考，请仔细甄别。



78 个网页

给 DeepSeek 发送消息

 深度思考

 智能搜索





内容由 AI 生成，请仔细甄别

地址：广州市 增城区 广深大道 邮编：510340

电邮：gzcovax@126.com QQ： 3987797287

第17页